



Indução de Árvores de Decisão

- Várias aplicações em Inteligência Artificial em tarefas de importância prática são baseadas na construção de um modelo de conhecimento que é utilizado por um especialista humano
- O objetivo desta aula é fornecer conceitos básicos sobre indução de árvores de decisão

Motivação


□ Dados pares $(x, f(x))$, inferir $f(\cdot)$

x	f(x)
1	1
2	4
3	9
4	16
5	?

Dada uma amostra finita, é freqüentemente impossível determinar a verdadeira função $f(\cdot)$

Abordagem: Encontre uma **hipótese** (**modelo**) nos exemplos de treinamento e assuma que a **hipótese** se repita para exemplos futuros também


Motivação



Exemplo	X_1	X_2	X_3	X_4	Y
z_1	0	1	1	0	0
z_2	0	0	0	0	0
z_3	0	0	1	1	1
z_4	1	0	0	1	1
z_5	0	1	1	0	0
z_6	1	1	0	0	0
z_7	0	1	0	1	0

□ $f: (X_1 \times X_2 \times X_3 \times X_4) \rightarrow Y$


Exemplo: Cogumelos Comestíveis x Venenosos



+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos




Suponha um novo cogumelo com $W=3$, $H=1$. Ele é comestível ou venenoso?

+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos




Suponha um novo cogumelo com $W=3$, $H=1$. Ele é comestível ou venenoso? A maioria das pessoas diria que é comestível, mas não há garantias que o cogumelo seja realmente comestível. Assim esta classificação é apenas uma *hipótese*

+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos




Em geral, a suposição principal em AM é que os objetos que parecem similares de alguma forma também pertencem à mesma classe

+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos




Pelo mesmo motivo de similaridade, um cogumelo com $W=5$, $H=4$ seria classificado como venenoso. Entretanto, é difícil decidir sobre um cogumelo com $W=2$, $H=2$.

+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos




Hipótese 1:
if $2 < W$ and $W < 4$ and $H < 2$
then comestível
else venenoso

+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos



Hipótese 1:

if $2 < W$ and $W < 4$ and $H < 2$
then comestível
else venenoso


Hipótese 2:

if $H > W$
then venenoso
else if $H > 6 - W$
then venenoso
else comestível

+ Comestível

- Venenoso

Exemplo: Cogumelos Comestíveis x Venenosos



Hipótese 1:

if $2 < W$ and $W < 4$ and $H < 2$
then comestível
else venenoso

Hipótese 2:

if $H > W$
then venenoso
else if $H > 6 - W$
then venenoso
else comestível

Hipótese 3:

if $H < 3 - (W - 3)^2$
then comestível
else venenoso

+ Comestível

- Venenoso

Sistemas de Aprendizado de Máquina – **Árvore de Decisão**

<i>Modos de Aprendizado</i>	<i>Paradigmas de Aprendizado</i>	<i>Linguagens de Descrição</i>	<i>Formas de Aprendizado</i>
☐ <u>Supervisionado</u> ☐ Não Supervisionado ☐ Semi Supervisionado	☐ <u>Simbólico</u> ☐ Estatístico ☐ Baseado em Exemplos (<i>Instance-Based</i>) ☐ Conexionista ☐ Genético	☐ <u>Instâncias ou Exemplos</u> ☐ <u>Hipótese expressa por uma Árvore de Decisão</u> ☐ Teoria de Domínio ou Conhecimento de Fundo	☐ Incremental ☐ <u>Não Incremental</u>

TDIDT


- ❑ Os algoritmos de classificação cujo conhecimento adquirido é representado como Árvore de Decisão (AD) pertencem a família TDIDT (*Top Down Induction of Decision Trees*)
- ❑ Árvore de Decisão: estrutura recursiva definida como:
 - um nó folha que indica uma classe, ou
 - um nó de decisão que contém um teste sobre o valor de um atributo. Cada resultado do teste leva a uma sub-árvore. Cada sub-árvore tem a mesma estrutura da árvore

AD para Jogar Tênis


□ Atributos:

- Aparência: *Sol, Nublado, Chuva*
- Umidade: *Alta, Normal*
- Ventando: *Forte, Fraco*
- Temperatura: *Quente, Média, Fria*
- Classe (Conceito Alvo) – jogar tênis: *Sim, Não*

AD para Jogar Tênis



AD para Jogar Tênis



AD para Jogar Tênis

Aparência Temperatura Umidade Ventando JogarTênis


Sol

Quente

Alta

Fraco

?



AD para Jogar Tênis

Aparência Temperatura Umidade Ventando Jogar Tênis


Sol

Quente

Alta

Fraco

?



AD para Jogar Tênis

Aparência Temperatura Umidade Ventando Jogar Tênis

Sol

Quente

Alta

Fraco

?

Aparência

Sol

Nublado

Chuva

Umidade

Sim

Ventando

Alta

Normal

Forte

Fraco

Não

Sim

Não

Sim

AD para Jogar Tênis

Aparência Temperatura Umidade Ventando Jogar Tênis

Sol

Quente

Alta

Fraco

?

Aparência

Sol

Nublado

Chuva

Umidade

Sim

Ventando

Alta

Normal

Forte

Fraco

Não

Sim

Não

Sim

AD para Jogar Tênis

Aparência Temperatura Umidade Ventando Jogar Tênis

Sol

Quente

Alta

Fraco

?

Aparência

Sol

Nublado

Chuva

Umidade

Sim

Ventando

Alta

Normal

Forte

Fraco


Não

Sim


Não

Sim

AD para Jogar Tênis



ADs Representam Disjunções de Conjunções




$(\text{Aparência}=\text{Sol} \wedge \text{Umidade}=\text{Normal}) \vee$
 $(\text{Aparência}=\text{Nublado}) \vee$
 $(\text{Aparência}=\text{Chuva} \wedge \text{Ventando}=\text{Fraco})$

Sim

$(\text{Aparência}=\text{Sol} \wedge \text{Umidade}=\text{Alta}) \vee$
 $(\text{Aparência}=\text{Chuva} \wedge \text{Ventando}=\text{Forte})$

Não

Exemplo: Árvore de Decisão




Paciente se sente bem = sim : saudável
Paciente se sente bem = não :
:....Paciente tem dor = não :
:....Temperatura do paciente ≤ 37: saudável
: Temperatura do paciente > 37: doente
Paciente tem dor = sim : doente

Representação da AD como um Conjunto de Regras

- ❑ Uma árvore pode ser representada como um conjunto de regras
- ❑ Cada regra começa na raiz da árvore e caminha para baixo, em direção às folhas
 - Cada nó de decisão acrescenta um teste às premissas (condições) da regra
 - O nó folha representa a conclusão da regra

Representação da AD como um Conjunto de Regras




```
if Paciente se sente bem = sim then
    classe = saudável
else
    if Paciente tem dor = não
        if Temperatura do paciente ≤ 37 then
            classe = saudável
        else {Temperatura do Paciente > 37}
            classe = doente
        end if
    else {Paciente tem dor = sim}
        classe = doente
    end if
end if
```

Representação da AD como um Conjunto de Regras Disjuntas

- ❑ As regras representadas por uma árvore de decisão são disjuntas
- ❑ Assim, elas podem ser escritas como regras **separadas**, começando pela raiz, e, conseqüentemente, o *else* não é necessário

Representação da AD como um Conjunto de Regras Disjuntas



```
if Paciente se sente bem = sim then  
    classe = saudável  
end if
```

```
if Paciente se sente bem = não  
    and Paciente tem dor = não  
    and Temperatura do paciente ≤ 37 then  
    classe = saudável  
end if
```

```
if Paciente se sente bem = não  
    and Paciente tem dor = não  
    and Temperatura do paciente > 37 then  
    classe = doente  
end if
```

```
if Paciente se sente bem = não  
    and Paciente tem dor = sim then  
    classe = doente  
end if
```

Qual é mais fácil de entender?

```
if Paciente se sente bem = sim then
  classe = saudável
else
  if Paciente tem dor = não
    if Temperatura do paciente ≤ 37 then
      classe = saudável
    else {Temperatura do Paciente > 37}
      classe = doente
    end if
  else {Paciente tem dor = sim}
    classe = doente
  end if
end if
```

```
if Paciente se sente bem = sim then
  classe = saudável
end if

if Paciente se sente bem = não
  and Paciente tem dor = não
  and Temperatura do paciente ≤ 37 then
    classe = saudável
  end if

if Paciente se sente bem = não
  and Paciente tem dor = não
  and Temperatura do paciente > 37 then
    classe = doente
  end if

if Paciente se sente bem = não
  and Paciente tem dor = sim then
    classe = doente
  end if
```

Algoritmo TDIDT

- ❑ Seja T um conjunto de exemplos de treinamento com classes $\{C_1, C_2, \dots, C_k\}$. Há três possibilidades:
 - 1) T contém um ou mais exemplos, todos pertencendo a uma mesma classe C_j : a árvore de decisão para T é uma folha identificando a classe C_j
 - 2) T não contém exemplos: a árvore de decisão é novamente uma folha, mas a classe associada com a folha deve ser determinada por alguma informação além de T . Por exemplo, a folha pode ser escolhida de acordo com algum conhecimento do domínio, tal como a classe majoritária. C4.5 utiliza a classe mais freqüente do nó pai deste nó (folha)
 - 3) T contém exemplos que pertencem a uma mistura de classes: nesta situação a idéia é refinar T em subconjuntos que são (ou aparentam ser) coleções de exemplos de uma única classe. Um teste é escolhido, baseado em um único atributo, com resultados mutuamente exclusivos. Sejam os possíveis resultados do teste denotados por $\{O_1, O_2, \dots, O_r\}$. T é então particionado em subconjuntos $T_1, T_2, \dots, T_r$, nos quais cada T_i contém todos os exemplos em T que possuem como resultado daquele teste o valor O_i . A árvore de decisão para T consiste em um nó (interno) identificado pelo teste escolhido e uma aresta para cada um dos resultados possíveis. Para cada partição, pode-se exigir que cada T_i contenha um número mínimo de exemplos, evitando partições com poucos exemplos. O default de C4.5 é de 2 exemplos
- ❑ Os passos 1, 2 e 3 são aplicados recursivamente para cada subconjunto de exemplos de treinamento de forma que, em cada nó, as arestas levam para as sub-árvores construídas a partir do subconjunto de exemplos T_i
- ❑ Após a construção da árvore de decisão, a poda pode ser realizada para melhorar sua capacidade de generalização

Pseudo código

```
function LearnDT(Training_Examples, Attributes, Default):Decision_Tree
  if IsEmptySet(Training_Examples) then return leaf(Default)
  if AllSameClass(Training_Examples) then return leaf(ClassOf(Training_Examples[0]))
  if IsEmptySet(Attributes) then return leaf(MajorityValue(Training_Examples))
  bestAttr = ChooseAttribute(Training_Examples,Attributes);
  node = new node(bestAtt)
  for each value v_i of bestAttr do
    Training_Examples_i = {elements of Training_Examples with bestAttr == v_i}
    subtree = LearnDT(Training_Examples_i,Attributes,MajorityValue(Training_Examples))
    add branch: node---v_i--->subtree
  end for
  return node
end
```

Classificando Novos Exemplos

- ❑ Uma AD pode ser usada para classificar novos exemplos (nunca vistos)
- ❑ A partir da raiz basta descer através dos nós de decisão até encontrar um nó folha: a classe correspondente a esse nó folha é a classe do novo exemplo
- ❑ Um exemplo (sem valores desconhecidos) é classificado apenas por uma regra (sub-árvore)

Exemplo (adaptado de Quinlan, 93)


- ❑ Neste exemplo, vamos considerar um conjunto de 15 exemplos que contém medições diárias sobre condições meteorológicas
- ❑ Atributos
 - aparência: “sol”, “nublado” ou “chuva”
 - temperatura: temperatura em graus Celsius
 - umidade: umidade relativa do ar
 - ventando: “sim” ou “não”
- ❑ Cada exemplo foi rotulado com “bom” se nas condições meteorológicas daquele dia é aconselhável fazer uma viagem à fazenda e “ruim”, caso contrário

O Conjunto de Dados “Viagem”

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom


Escolhendo “Aparência” para Particionar

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




Escolhendo “Umidade” para Particionar “Aparência=sol”

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




Escolhendo “Umidade” para Particionar “Aparência=nublado”

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




Escolhendo “Ventando” para Particionar “Aparência=chuva”

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




Árvore de Decisão Induzida (sem poda)

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




Árvore de Decisão Induzida (sem poda)

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




Árvore de Decisão Induzida (podada)

Exemplo	Aparência	Temperatura	Umidade	Ventando	Viajar
E ₁	sol	25	72	sim	bom
E ₂	sol	28	91	sim	ruim
E ₃	sol	22	70	não	bom
E ₄	sol	23	95	não	ruim
E ₅	sol	30	85	não	ruim
E ₆	nublado	23	90	sim	bom
E ₇	nublado	29	78	não	bom
E ₈	nublado	19	65	sim	ruim
E ₉	nublado	26	75	não	bom
E ₁₀	nublado	20	87	sim	bom
E ₁₁	chuva	22	95	não	bom
E ₁₂	chuva	19	70	sim	ruim
E ₁₃	chuva	23	80	sim	ruim
E ₁₄	chuva	25	81	não	bom
E ₁₅	chuva	21	80	não	bom




(Pós-)Poda

- ❑ Uma árvore maior é induzida de forma a superajustar os exemplos e então ela é podada até obter uma árvore menor (mais simples)
- ❑ A poda evita *overfitting*



Relação entre Tamanho da Árvore de Decisão e a Taxa de Erro




Escolha do Atributo

- ❑ A maioria dos algoritmos de construção de árvores de decisão são sem retrocesso (sem *backtracking*) ou seja, gulosos (*greedy*)
- ❑ Uma vez que um teste foi selecionado para particionar o conjunto atual de exemplos, a escolha é fixada e escolhas alternativas não são exploradas

Escolha do Atributo

- ❑ A chave para o sucesso de um algoritmo de aprendizado por árvores de decisão depende do critério utilizado para escolher o atributo que particiona o conjunto de exemplos em cada iteração
- ❑ Algumas possibilidades para escolher esse atributo são:
 - aleatória: seleciona qualquer atributo aleatoriamente
 - menos valores: seleciona o atributo com a menor quantidade de valores possíveis
 - mais valores: seleciona o atributo com a maior quantidade de valores possíveis
 - ganho máximo: seleciona o atributo que possui o maior ganho de informação esperado, isto é, seleciona o atributo que resultará no menor tamanho esperado das subárvores, assumindo que a raiz é o nó atual;
 - razão de ganho
 - índice Gini

Exemplo




Tira uma bola aleatoriamente –

- Qual a melhor sequencia de perguntas?
- Qual o número médio de perguntas?


8 bolas: 4 , 2 , 1 , 1 

Exemplo

❑ Melhor conjunto de perguntas (Codigo de Huffman)



O código de Huffman foi desenvolvido por David A. Huffman quando era aluno de PhD no MIT em 1952, e publicado no artigo: *A Method for the Construction of Minimum-Redundancy Codes*.



Professor David A. Huffman
(August 9, 1925 - October 7, 1999)

Exemplo

□ Número médio de perguntas :


$$P(\text{red}) \times 1 + P(\text{blue}) \times 2 + P(\text{green}) \times 3 + P(\text{purple}) \times 3$$

$$\frac{1}{2} \times 1 + \frac{1}{4} \times 2 + \frac{1}{8} \times 3 + \frac{1}{8} \times 3 = 1.75$$


□ Entropia = $-\sum_i p_i \log_2(p_i)$

$$= \frac{1}{2} \times \log_2\left(\frac{1}{2}\right) + \frac{1}{4} \times \log_2\left(\frac{1}{4}\right) + \left(\frac{1}{8}\right) \times \log_2\left(\frac{1}{8}\right) + \left(\frac{1}{8}\right) \times \log_2\left(\frac{1}{8}\right) = 1.75 \text{ bits}$$


Teoria da Informação



- Claude E. Shannon
(1916-2001)
- 1948: *A Mathematical Theory of Communication*
 - *A entropia mede a falta de informação (medida de desordem) de um sistema*



A entropia da
água em estado
líquido é maior
que a entropia
da água em
estado sólido (0°
C)



A entropia de

gases > líquidos > sólidos

Entropia

- ❑ Pode também ser considerada como uma medida da quantidade de informação que uma pessoa necessita para organizar seus conhecimentos e descobrir uma regra
- ❑ Quanto mais alternativas um diagnóstico possui, mais informações são necessárias para aprender ele (maior entropia)
- ❑ Se um diagnóstico não tem alternativas, não é necessária nenhuma informação (entropia = 0)

Entropia

- Seja S um subconjunto de T
- A informação esperada (ou entropia) do subconjunto S é (em bits) dado por

$$\text{info}(S) = - \sum_{j=1}^k p(C_j, S) \times \log_2(p(C_j, S))$$

$$p(C_j, S) = \frac{\text{freq}(C_j, S)}{|S|} = \frac{\text{número de exemplos em } S \text{ com classe } C_j}{\text{número de exemplos em } S}$$

Entropia

- ❑ Quando aplicado a todo o conjunto de treinamento T , **info(T)** mede a quantidade média de informação necessária para identificar a classe de um exemplo em T
- ❑ Lembrar que **$\log_b(a) = \ln(a) / \ln(b)$**
ou seja, **$\log_2(x) = \ln(x) / \ln(2)$**
- ❑ Observação: assumir **$0 * \log_2(0) = 0$**

Entropia

❑ Considere o conjunto de exemplos T com a seguinte proporção de exemplos $+$ e $-$

❑ (50%,50%) $info(T) = 1$

❑ (20%,80%) $info(T) = 0.722$

❑ (100%, 0%) $info(T) = 0$

Pode ser observado que quando T vai ficando mais “puro”, a entropia vai ficando menor. Para duas classes, o valor da entropia fica no intervalo $[1,0]$

Exercício

□ Calcule $\text{info}(T)$ para

- Um conjunto T de 64 exemplos, sendo 29 exemplos da classe positiva e 35 da classe negativa, ou seja, $[29+, 35-]$
- Um conjunto T de 64 exemplos, sendo 20 exemplos da classe positiva, 32 da classe negativa e 12 da classe asterisco, ou seja, $[20+, 32-, 12^*]$
- Idem para $T = [20+, 32-, 6^*, 6\$]$

Solução

□ $T = [29+, 35-]$

- $\text{info}(T) = \text{info}([29+, 35-])$
 $= -29/64 \log_2 29/64 - 35/64 \log_2 35/64$
 $= 0.99$

□ $T = [20+, 32-, 12^*]$

- $\text{info}(T) = \text{info}([20+, 32-, 12^*])$
 $= -20/64 \log_2 20/64 - 32/64 \log_2 32/64$
 $\quad - 12/64 \log_2 12/64$
 $= 1.48$

□ $T = [20+, 32-, 6^*, 6\$]$

- $\text{info}(T) = \text{info}([20+, 32-, 6^*, 6\$])$
 $= -20/64 \log_2 20/64 - 32/64 \log_2 32/64$
 $\quad - 6/64 \log_2 6/64 - 6/64 \log_2 6/64$
 $= 1.66$


Entropia

- Considere agora que T foi particionado de acordo com r valores do atributo X , ou seja $X = O_1, X = O_2, \dots, X = O_r$, gerando os subconjuntos $T_1, T_2, \dots, T_r$, respectivamente
 - T_i é o formado pelos exemplos de T nos quais o atributo $X = O_i$, ou seja, $T_i = \{\forall z \in T: X = O_i\}$
- A informação esperada para este particionamento é a soma ponderada sobre todos os subconjuntos T_i :

$$\text{info}(X, T) = \sum_{i=1}^r \frac{|T_i|}{|T|} \times \text{info}(T_i)$$


- lembrando que $|T|$ é a cardinalidade do conjunto T

Exercício



Calcule $\text{info}(X_1, T)$ e $\text{info}(X_2, T)$, $T = [29+, 35-]$

Solução



$$\text{info}([21+,5-]) = 0.71$$


$$\text{info}([8+,30-]) = 0.74$$

$$\text{info}(X_1,[29+,35-]) =$$

$$-26/64 * \text{info}([21+,5-])$$

$$-38/64 * \text{info}([8+,30-])$$

$$= 0.73$$



$$\text{info}([18+,32-]) = 0.94$$

$$\text{info}([7+,1-]) = 0.54$$

$$\text{info}([4+,2-]) = 0.92$$

$$\begin{aligned} \text{info}(X_2,[29+,35-]) &= -50/64 * \text{info}([18+,32-]) - \\ &\quad 8/64 * \text{info}([7+,1-]) - 6/64 * \text{info}([4+,2-]) \\ &= 0.89 \end{aligned}$$

Ganho de Informação

□ A quantidade


- $\text{gain}(X, T) = \text{info}(T) - \text{info}(X, T)$
- mede o ganho de informação pela partição de T de acordo com o atributo X

□ O critério de ganho (ganho máximo)

seleciona o atributo $X \in T$ (ou seja, $X \in \{X_1, X_2, \dots, X_m\}$) que maximiza o ganho de informação

$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T))$$

Exercício




$T = [29+, 35-]$

$\text{info}([29+, 35-]) = 0.99$

$\text{info}(X_1, [29+, 35-]) = 0.73$


$\text{info}(X_2, [29+, 35-]) = 0.89$



Qual o ganho de X_1 ? E de X_2 ?

Com qual atributo obtém-se o ganho máximo?

Solução




$T = [29+,35-]$

$\text{info}([29+,35-]) = 0.99$

$\text{info}(X_1, [29+,35-]) = 0.73$

$\text{info}(X_2, [29+,35-]) = 0.89$



$$\begin{aligned}\text{gain}(X_1, T) &= \text{info}(T) - \text{info}(X_1, T) \\ &= 0.99 - 0.73 = \mathbf{0.26}\end{aligned}$$

$$\begin{aligned}\text{gain}(X_2, T) &= \text{info}(T) - \text{info}(X_2, T) \\ &= 0.99 - 0.89 = 0.10\end{aligned}$$

Ganho máximo é obtido com X_1

Exemplo

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₁	sol	quente	alta	falso	não
E ₂	sol	quente	alta	verdadeiro	não
E ₃	nublado	quente	alta	falso	sim
E ₄	chuva	agradável	alta	falso	sim
E ₅	chuva	fria	normal	falso	sim
E ₆	chuva	fria	normal	verdadeiro	não
E ₇	nublado	fria	normal	verdadeiro	sim
E ₈	sol	agradável	alta	falso	não
E ₉	sol	fria	normal	falso	sim
E ₁₀	chuva	agradável	normal	falso	sim
E ₁₁	sol	agradável	normal	verdadeiro	sim
E ₁₂	nublado	agradável	alta	verdadeiro	sim
E ₁₃	nublado	quente	normal	falso	sim
E ₁₄	chuva	agradável	alta	verdadeiro	não

Exemplo

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₁	sol	quente	alta	falso	não
E ₂	sol	quente	alta	verdadeiro	não
E ₃	nublado	quente	alta	falso	sim
E ₄	chuva	agradável	alta	falso	sim
E ₅	chuva	fria	normal	falso	sim
E ₆	chuva	fria	normal	verdadeiro	não
E ₇	nublado	fria	normal	verdadeiro	sim
E ₈	sol	agradável	alta	falso	não
E ₉	sol	fria	normal	falso	sim
E ₁₀	chuva	agradável	normal	falso	sim
E ₁₁	sol	agradável	normal	verdadeiro	sim
E ₁₂	nublado	agradável	alta	verdadeiro	sim
E ₁₃	nublado	quente	normal	falso	sim
E ₁₄	chuva	agradável	alta	verdadeiro	não

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim 9
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não 5
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total 14

$$\begin{aligned}
\text{info}(T) &= -\sum_{j=1}^2 p(C_j, T) \times \log_2(p(C_j, T)) \\
&= -p(\text{sim}, T) \times \log_2(p(\text{sim}, T)) - p(\text{não}, T) \times \log_2(p(\text{não}, T)) \\
&= -\frac{9}{14} \times \log_2\left(\frac{9}{14}\right) - \frac{5}{14} \times \log_2\left(\frac{5}{14}\right) \\
&= 0.94029 \text{ bits}
\end{aligned}$$

$$\begin{aligned}
\text{info}(\text{Aparência}, T) &= \sum_{i=1}^3 \frac{|T_i|}{|T|} \times \text{info}(T_i) \\
&= \frac{|T_{\text{sol}}|}{|T|} \times \text{info}(T_{\text{sol}}) + \frac{|T_{\text{nublado}}|}{|T|} \times \text{info}(T_{\text{nublado}}) + \frac{|T_{\text{chuva}}|}{|T|} \times \text{info}(T_{\text{chuva}}) \\
&= \frac{5}{14} \times \text{info}(T_{\text{sol}}) + \frac{4}{14} \times \text{info}(T_{\text{nublado}}) + \frac{5}{14} \times \text{info}(T_{\text{chuva}})
\end{aligned}$$

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim 9
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não 5
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total 14

$$\text{info}(T_{sol}) = -\sum_{j=1}^2 p(C_j, T_{sol}) \times \log_2(p(C_j, T_{sol}))$$

$$= -p(\text{sim}, T_{sol}) \times \log_2(p(\text{sim}, T_{sol})) - p(\text{não}, T_{sol}) \times \log_2(p(\text{não}, T_{sol}))$$

$$= -\frac{2}{5} \times \log_2\left(\frac{2}{5}\right) - \frac{3}{5} \times \log_2\left(\frac{3}{5}\right) = 0.97095$$

$$\text{info}(T_{nublado}) = -\sum_{j=1}^2 p(C_j, T_{nublado}) \times \log_2(p(C_j, T_{nublado}))$$

$$= -p(\text{sim}, T_{nublado}) \times \log_2(p(\text{sim}, T_{nublado})) - p(\text{não}, T_{nublado}) \times \log_2(p(\text{não}, T_{nublado}))$$

$$= -\frac{4}{4} \times \log_2\left(\frac{4}{4}\right) - \frac{0}{4} \times \log_2\left(\frac{0}{4}\right) = 0$$

$$\text{info}(T_{chuva}) = -\sum_{j=1}^2 p(C_j, T_{chuva}) \times \log_2(p(C_j, T_{chuva}))$$

$$= -p(\text{sim}, T_{chuva}) \times \log_2(p(\text{sim}, T_{chuva})) - p(\text{não}, T_{chuva}) \times \log_2(p(\text{não}, T_{chuva}))$$

$$= -\frac{3}{5} \times \log_2\left(\frac{3}{5}\right) - \frac{2}{5} \times \log_2\left(\frac{2}{5}\right) = 0.97095$$

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim 9
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não 5
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total 14

$$\begin{aligned}
\text{info}(\text{Aparência}, T) &= \sum_{i=1}^3 \frac{|T_i|}{|T|} \times \text{info}(T_i) \\
&= \frac{|T_{\text{sol}}|}{|T|} \times \text{info}(T_{\text{sol}}) + \frac{|T_{\text{nublado}}|}{|T|} \times \text{info}(T_{\text{nublado}}) + \frac{|T_{\text{chuva}}|}{|T|} \times \text{info}(T_{\text{chuva}}) \\
&= \frac{5}{14} \times \text{info}(T_{\text{sol}}) + \frac{4}{14} \times \text{info}(T_{\text{nublado}}) + \frac{5}{14} \times \text{info}(T_{\text{chuva}}) \\
&= \frac{5}{14} \times \left(-\frac{2}{5} \times \log_2 \left(\frac{2}{5} \right) - \frac{3}{5} \times \log_2 \left(\frac{3}{5} \right) \right) \\
&\quad + \frac{4}{14} \times \left(-\frac{4}{4} \times \log_2 \left(\frac{4}{4} \right) - \frac{0}{4} \times \log_2 \left(\frac{0}{4} \right) \right) \\
&\quad + \frac{5}{14} \times \left(-\frac{3}{5} \times \log_2 \left(\frac{3}{5} \right) - \frac{2}{5} \times \log_2 \left(\frac{2}{5} \right) \right) \\
&= 0.69354 \text{ bits}
\end{aligned}$$

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim 9
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não 5
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total 14

$$\begin{aligned}
\text{info}(\text{Temperatura}, T) &= \sum_{i=1}^3 \frac{|T_i|}{|T|} \times \text{info}(T_i) \\
&= \frac{|T_{\text{quente}}|}{|T|} \times \text{info}(T_{\text{quente}}) + \frac{|T_{\text{agradável}}|}{|T|} \times \text{info}(T_{\text{agradável}}) + \frac{|T_{\text{fria}}|}{|T|} \times \text{info}(T_{\text{fria}}) \\
&= \frac{4}{14} \times \left(-\frac{2}{4} \times \log_2 \left(\frac{2}{4} \right) - \frac{2}{4} \times \log_2 \left(\frac{2}{4} \right) \right) \\
&\quad + \frac{6}{14} \times \left(-\frac{4}{6} \times \log_2 \left(\frac{4}{6} \right) - \frac{2}{6} \times \log_2 \left(\frac{2}{6} \right) \right) \\
&\quad + \frac{4}{14} \times \left(-\frac{3}{4} \times \log_2 \left(\frac{3}{4} \right) - \frac{1}{4} \times \log_2 \left(\frac{1}{4} \right) \right) \\
&= 0.91106 \text{ bits}
\end{aligned}$$

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim 9
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não 5
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total 14

$$\begin{aligned}
\text{info}(\text{Umidade}, T) &= \sum_{i=1}^2 \frac{|T_i|}{|T|} \times \text{info}(T_i) \\
&= \frac{|T_{\text{alta}}|}{|T|} \times \text{info}(T_{\text{alta}}) + \frac{|T_{\text{normal}}|}{|T|} \times \text{info}(T_{\text{normal}}) \\
&= \frac{7}{14} \times \left(-\frac{3}{7} \times \log_2 \left(\frac{3}{7} \right) - \frac{4}{7} \times \log_2 \left(\frac{4}{7} \right) \right) \\
&\quad + \frac{7}{14} \times \left(-\frac{6}{7} \times \log_2 \left(\frac{6}{7} \right) - \frac{1}{7} \times \log_2 \left(\frac{1}{7} \right) \right) \\
&= 0.78845 \text{ bits}
\end{aligned}$$

Aparência	sim	não	Total	Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	quente	2	2	4	alta	3	4	7	falso	6	2	8	sim 9
nublado	4	0	4	agradável	4	2	6	normal	6	1	7	verdadeiro	3	3	6	não 5
chuva	3	2	5	fria	3	1	4									
Total	9	5	14	Total	9	5	14	Total	9	5	14	Total	9	5	14	Total 14

$$\begin{aligned}
\text{info}(\text{Ventando}, T) &= \sum_{i=1}^2 \frac{|T_i|}{|T|} \times \text{info}(T_i) \\
&= \frac{|T_{falso}|}{|T|} \times \text{info}(T_{falso}) + \frac{|T_{verdadeiro}|}{|T|} \times \text{info}(T_{verdadeiro}) \\
&= \frac{8}{14} \times \left(-\frac{6}{8} \times \log_2 \left(\frac{6}{8} \right) - \frac{2}{8} \times \log_2 \left(\frac{2}{8} \right) \right) \\
&\quad + \frac{6}{14} \times \left(-\frac{3}{6} \times \log_2 \left(\frac{3}{6} \right) - \frac{3}{6} \times \log_2 \left(\frac{3}{6} \right) \right) \\
&= 0.89216 \text{ bits}
\end{aligned}$$

Escolha do Atributo para Particionar todo o Conjunto de Exemplos

$$\text{info}(T) = 0.94029 \text{ bits}$$

$$\text{info}(\text{Aparência}, T) = 0.69354 \text{ bits}$$

$$\text{info}(\text{Temperatura}, T) = 0.91106 \text{ bits}$$

$$\text{info}(\text{Umidade}, T) = 0.78845 \text{ bits}$$

$$\text{info}(\text{Ventando}, T) = 0.89216 \text{ bits}$$

$$\text{gain}(\text{Aparência}, T) = \text{info}(T) - \text{info}(\text{Aparência}, T) = 0.94029 - 0.69354 = 0.24675 \text{ bits}$$


$$\text{gain}(\text{Temperatura}, T) = \text{info}(T) - \text{info}(\text{Temperatura}, T) = 0.94029 - 0.91106 = 0.02922 \text{ bits}$$

$$\text{gain}(\text{Umidade}, T) = \text{info}(T) - \text{info}(\text{Umidade}, T) = 0.94029 - 0.78845 = 0.15184 \text{ bits}$$


$$\text{gain}(\text{Ventando}, T) = \text{info}(T) - \text{info}(\text{Ventando}, T) = 0.94029 - 0.89216 = 0.04813 \text{ bits}$$

$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T)) = \text{Aparência}$$


O Subconjunto “Aparência=nublado” possui Apenas Exemplos de uma Mesma Classe...




...o que Leva a um Nó Folha



Escolha do Atributo para Particionar “Aparência=sol”



Escolha do Atributo para Particionar “Aparência=sol”



$$\text{info}(T) = 0.97095 \text{ bits}$$

$$\text{info}(\text{Temperatura}, T) = 0.4 \text{ bits}$$

$$\text{info}(\text{Umidade}, T) = 0 \text{ bits}$$

$$\text{info}(\text{Ventando}, T) = 0.95098 \text{ bits}$$


$$\text{gain}(\text{Temperatura}, T) = \text{info}(T) - \text{info}(\text{Temperatura}, T) = 0.97095 - 0.4 = 0.57095 \text{ bits}$$

$$\text{gain}(\text{Umidade}, T) = \text{info}(T) - \text{info}(\text{Umidade}, T) = 0.97095 - 0 = 0.97095 \text{ bits}$$

$$\text{gain}(\text{Ventando}, T) = \text{info}(T) - \text{info}(\text{Ventando}, T) = 0.97095 - 0.95098 = 0.01997 \text{ bits}$$

$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T)) = \text{Umidade}$$

Escolha do Atributo “Umidade” para Particionar “Aparência=sol”




Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	agradável	alta	falso	sim
E ₅	chuva	fria	normal	falso	sim
E ₆	chuva	fria	normal	verdadeiro	não
E ₁₀	chuva	agradável	normal	falso	sim
E ₁₄	chuva	agradável	alta	verdadeiro	não


Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₁	sol	quente	alta	falso	não
E ₂	sol	quente	alta	verdadeiro	não
E ₈	sol	agradável	alta	falso	não

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₉	sol	fria	normal	falso	sim
E ₁₁	sol	agradável	normal	verdadeiro	sim

Escolha do Atributo para Particionar “Aparência=chuva”



Escolha do Atributo para Particionar “Aparência=chuva”



Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	agradável	alta	falso	sim
E ₅	chuva	fria	normal	falso	sim
E ₆	chuva	fria	normal	verdadeiro	não
E ₁₀	chuva	agradável	normal	falso	sim
E ₁₄	chuva	agradável	alta	verdadeiro	não

Temperatura	sim	não	Total	Umidade	sim	não	Total	Ventando	sim	não	Total	Jogar
quente	0	0	0	alta	1	1	2	falso	3	0	3	sim
agradável	2	1	3	normal	2	1	3	verdadeiro	0	2	2	não
fria	1	1	2									
Total	3	2	5	Total	3	2	5	Total	3	2	5	Total

$$\text{info}(T) = 0.97095 \text{ bits}$$

$$\text{info}(\text{Temperatura}, T) = 0.95098 \text{ bits}$$

$$\text{info}(\text{Umidade}, T) = 0.95098 \text{ bits}$$

$$\text{info}(\text{Ventando}, T) = 0 \text{ bits}$$


$$\text{gain}(\text{Temperatura}, T) = \text{info}(T) - \text{info}(\text{Temperatura}, T) = 0.97095 - 0.95098 = 0.01997 \text{ bits}$$

$$\text{gain}(\text{Umidade}, T) = \text{info}(T) - \text{info}(\text{Umidade}, T) = 0.97095 - 0.95098 = 0.01997 \text{ bits}$$

$$\text{gain}(\text{Ventando}, T) = \text{info}(T) - \text{info}(\text{Ventando}, T) = 0.97095 - 0 = 0.97095 \text{ bits}$$

$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T)) = \text{Ventando}$$


Escolha do Atributo “Ventando” para Particionar “Aparência=chuva”



Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	agradável	alta	falso	sim
E ₅	chuva	fria	normal	falso	sim
E ₁₀	chuva	agradável	normal	falso	sim

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₆	chuva	fria	normal	verdadeiro	não
E ₁₄	chuva	agradável	alta	verdadeiro	não

Árvore de Decisão Induzida



Exercício

□ Calcule o ganho para o atributo “Dia”, ou seja, $\text{gain}(\text{Dia}, T)$, sabendo que $\text{info}(T) = 0.94$


- $\text{gain}(\text{Dia}, T) = \text{info}(T) - \text{info}(\text{Dia}, T)$

Dia	Aparência	Temperatura	Umidade	Ventando	Jogar
d1	sol	quente	alta	falso	não
d2	sol	quente	alta	verdadeiro	não
d3	nublado	quente	alta	falso	sim
d4	chuva	agradável	alta	falso	sim
d5	chuva	fria	normal	falso	sim
d6	chuva	fria	normal	verdadeiro	não
d7	nublado	fria	normal	verdadeiro	sim
d8	sol	agradável	alta	falso	não
d9	sol	fria	normal	falso	sim
d10	chuva	agradável	normal	falso	sim
d11	sol	agradável	normal	verdadeiro	sim
d12	nublado	agradável	alta	verdadeiro	sim
d13	nublado	quente	normal	falso	sim
d14	chuva	agradável	alta	verdadeiro	não

Razão de Ganho

- ❑ Vimos que o ganho máximo é interessante para particionar os exemplos, fornecendo bons resultados
- ❑ Entretanto, ele tem uma tendência (*bias*) em favor de testes com muitos valores
- ❑ Por exemplo, considere um conjunto de exemplos de diagnóstico médico no qual um dos atributos contém o código de identificação do paciente (ID)
- ❑ Uma vez que cada código ID é único, particionando o conjunto de treinamento nos valores deste atributo levará a um grande número de subconjuntos, cada um contendo somente um caso
- ❑ Como todos os subconjuntos (de 1 elemento) necessariamente contêm exemplos de uma mesma classe, $\text{info}(\text{ID}, T) = 0$, assim o ganho de informação deste atributo será máximo

Razão de Ganho



Razão de Ganho

- Para solucionar esta situação, em analogia à definição de $\text{info}(T)$, vamos definir a informação potencial gerada pela partição de T em r subconjuntos

$$\text{split-info}(X, T) = - \sum_{i=1}^r \frac{|T_i|}{|T|} \times \log_2 \left(\frac{|T_i|}{|T|} \right)$$

- A razão de ganho é definida como:

$$\text{gain-ratio}(X, T) = \frac{\text{gain}(X, T)}{\text{split-info}(X, T)}$$

- A razão de ganho expressa a proporção de informação gerada pela partição que é útil, ou seja, que aparenta ser útil para a classificação

Razão de Ganho

- Usando o exemplo anterior para o atributo Aparência que produz três subconjuntos com 5, 4 e 5 exemplos, respectivamente

$$\begin{aligned}\text{split-info}(\text{Aparência}, T) &= -\frac{5}{14} \times \log_2\left(\frac{5}{14}\right) - \frac{4}{14} \times \log_2\left(\frac{4}{14}\right) - \frac{5}{14} \times \log_2\left(\frac{5}{14}\right) \\ &= 1.57741 \text{ bits}\end{aligned}$$

- Para este teste, cujo ganho é $\text{gain}(\text{Aparência}, T) = 0.24675$ (mesmo valor anterior), a razão de ganho é
 - $\text{gain-ratio}(\text{Aparência}, T) = 0.24675 / 1.57741 = 0.156428$

Atributos Numéricos

- ❑ Se um atributo X assume valores reais (numéricos), é gerado um teste binário cujos resultados são $X \leq Z$ e $X > Z$
- ❑ O limite Z pode ser encontrado da seguinte forma
 - Os exemplos de T são inicialmente ordenados considerando os valores do atributo X sendo considerado
 - Há apenas um conjunto finito de valores, que podemos denotar (em ordem) por $\{v_1, v_2, \dots, v_L\}$
 - Qualquer limite caindo entre v_i e v_{i+1} tem o mesmo efeito que particionar os exemplos cujos valores do atributo X encontra-se em $\{v_1, v_2, \dots, v_i\}$ e em $\{v_{i+1}, v_{i+2}, \dots, v_L\}$
 - Assim, existem apenas $L-1$ divisões possíveis para o atributo X , cada uma devendo ser examinada
 - Isso pode ser obtido (uma vez ordenados os valores) em uma única passagem, atualizando as distribuições de classes para a esquerda e para a direita do limite Z durante o processo
 - Alguns indutores podem escolher o valor de limite como sendo o ponto médio de cada intervalo $Z = (v_i + v_{i+1})/2$
 - C4.5, entretanto, escolhe o maior valor de Z entre todo o conjunto de treinamento que não excede o ponto médio acima, assegurando que todos os valores que aparecem na árvore de fato ocorrem nos dados

Exemplo (atributos numéricos)

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₁	sol	85	85	falso	não
E ₂	sol	80	90	verdadeiro	não
E ₃	nublado	83	86	falso	sim
E ₄	chuva	70	96	falso	sim
E ₅	chuva	68	80	falso	sim
E ₆	chuva	65	70	verdadeiro	não
E ₇	nublado	64	65	verdadeiro	sim
E ₈	sol	72	95	falso	não
E ₉	sol	69	70	falso	sim
E ₁₀	chuva	75	80	falso	sim
E ₁₁	sol	75	70	verdadeiro	sim
E ₁₂	nublado	72	90	verdadeiro	sim
E ₁₃	nublado	81	75	falso	sim
E ₁₄	chuva	71	91	verdadeiro	não


Escolha do Atributo para Particionar todo o Conjunto de Exemplos

Aparência	sim	não	Total	Ventando	sim	não	Total	Jogar
sol	2	3	5	falso	6	2	8	sim 9
nublado	4	0	4	verdadeiro	3	3	6	não 5
chuva	3	2	5					
Total	9	5	14	Total	9	5	14	Total 14


Temperatura	64	65	68	69	70	71	72	75	80	81	83	85
Jogar	sim	não	sim	sim	sim	não	não sim	sim sim	não	sim	sim	não

Umidade	65	70	75	80	85	86	90	91	95	96
Jogar	sim	não sim sim	sim	sim sim	não	sim	não sim	não	não	sim

Escolha do Atributo para Particionar todo o Conjunto de Exemplos



Escolha do Atributo para Particionar todo o Conjunto de Exemplos



Escolha do Atributo para Particionar todo o Conjunto de Exemplos

$$\text{info}(T) = 0.94029 \text{ bits}$$

$$\text{info}(\text{Aparência}, T) = 0.69354 \text{ bits}$$

$$\text{info}(\text{Temperatura}_{Z=84}, T) = 0.93980 \text{ bits}$$

$$\text{info}(\text{Umidade}_{Z=82.5}, T) = 0.92997 \text{ bits}$$

$$\text{info}(\text{Ventando}, T) = 0.89216 \text{ bits}$$

$$\text{gain}(\text{Aparência}, T) = 0.24675 \text{ bits}$$


$$\text{gain}(\text{Temperatura}_{Z=84}, T) = 0.11340 \text{ bits}$$

$$\text{gain}(\text{Umidade}_{Z=82.5}, T) = 0.15184 \text{ bits}$$

$$\text{gain}(\text{Ventando}, T) = 0.04813 \text{ bits}$$


$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T)) = \text{Aparência}$$

O Subconjunto “Aparência=nublado” possui Apenas Exemplos de uma Mesma Classe, Levando a um Nó Folha



Escolha do Atributo para Particionar


“Aparência=sol”



Escolha do Atributo para Particionar

“Aparência=sol”

Temperatura	64	65	68	69	70	71	72	75	80	81	83	85
-------------	----	----	----	----	----	----	----	----	----	----	----	----




Escolha do Atributo para Particionar


“Aparência=sol”

$$Z = (70 + 85) / 2 = 77.5$$

Umidade	65	70	75	80	85	86	90	91	95	96
---------	----	----	----	----	----	----	----	----	----	----



Escolha do Atributo para Particionar “Aparência=sol”



Ventando	sim	não	Total	Jogar
falso	1	2	3	sim 2
verdadeiro	1	1	2	não 3
Total	2	3	5	Total 5

Temperatura	69	72	75	80	85
Jogar	sim	não	sim	não	não

Umidade	70	85	90	95
Jogar	sim sim	não	não	não

$$\text{info}(T) = 0.97095 \text{ bits}$$

$$\text{info}(\text{Temperatura}_{Z=77.5}, T) = 0.55098 \text{ bits}$$

$$\text{info}(\text{Umidade}_{Z=77.5}, T) = 0 \text{ bits}$$

$$\text{info}(\text{Ventando}, T) = 0.95098 \text{ bits}$$


$$\text{gain}(\text{Temperatura}_{Z=77.5}, T) = 0.97095 - 0.55098 = 0.41997$$

$$\text{gain}(\text{Umidade}_{Z=77.5}, T) = 0.97095 - 0 = 0.97095 \text{ bits}$$

$$\text{gain}(\text{Ventando}, T) = 0.97095 - 0.95098 = 0.01997 \text{ bits}$$

$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T)) = \text{Umidade}_{Z=77.5}$$

Escolha do Atributo “Umidade” para Particionar “Aparência=sol”




Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	70	96	falso	sim
E ₅	chuva	68	80	falso	sim
E ₆	chuva	65	70	verdadeiro	não
E ₁₀	chuva	75	80	falso	sim
E ₁₄	chuva	71	91	verdadeiro	não

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₉	sol	69	70	falso	sim
E ₁₁	sol	75	70	verdadeiro	sim

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₁	sol	85	85	falso	não
E ₂	sol	80	90	verdadeiro	não
E ₈	sol	72	95	falso	não

Escolha do Atributo para Particionar “Aparência=chuva”



Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	70	96	falso	sim
E ₅	chuva	68	80	falso	sim
E ₆	chuva	65	70	verdadeiro	não
E ₁₀	chuva	75	80	falso	sim
E ₁₄	chuva	71	91	verdadeiro	não

Temperatura	65	68	70	71	75
Jogar	não	sim	sim	não	sim

Umidade	70	80	91	96
Jogar	não	sim	sim	sim


Ventando	sim	não	Total	Jogar
falso	3	0	3	sim 3
verdadeiro	0	2	2	não 2
Total	3	2	5	Total 5

Escolha do Atributo para Particionar “Aparência=chuva”

$$Z = (65 + 68) / 2 = 66.5$$

Temperatura	64	65	68	69	70	71	72	75	80	81	83	85
-------------	----	----	----	----	----	----	----	----	----	----	----	----


Temperatura (Aparência=chuva)




Escolha do Atributo para Particionar “Aparência=chuva”

$$Z=(70+80)/2=75$$

Umidade	65	70	75	80	85	86	90	91	95	96
---------	----	----	----	----	----	----	----	----	----	----



Escolha do Atributo para Particionar “Aparência=chuva”



Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	70	96	falso	sim
E ₅	chuva	68	80	falso	sim
E ₆	chuva	65	70	verdadeiro	não
E ₁₀	chuva	75	80	falso	sim
E ₁₄	chuva	71	91	verdadeiro	não

Temperatura	65	68	70	71	75
Jogar	não	sim	sim	não	sim

Umidade	70	80	91	96
Jogar	não	sim	não	sim

Ventando	sim	não	Total	Jogar
falso	3	0	3	sim 3
verdadeiro	0	2	2	não 2
Total	3	2	5	Total 5

$$\text{info}(T) = 0.97095 \text{ bits}$$

$$\text{info}(\text{Temperatura}_{Z=66.5}, T) = 0.64902 \text{ bits}$$

$$\text{info}(\text{Umidade}_{Z=75}, T) = 0.64902 \text{ bits}$$

$$\text{info}(\text{Ventando}, T) = 0 \text{ bits}$$


$$\text{gain}(\text{Temperatura}, T) = 0.97095 - 0.64902 = 0.32193 \text{ bits}$$

$$\text{gain}(\text{Umidade}, T) = 0.97095 - 0.64902 = 0.32193 \text{ bits}$$

$$\text{gain}(\text{Ventando}, T) = 0.97095 - 0 = 0.97095 \text{ bits}$$

$$\max(\text{gain}(X, T)) = \arg \max_{X \in \{X_1, X_2, \dots, X_m\}} (\text{gain}(X, T)) = \text{Ventando}$$


Escolha do Atributo “Ventando” para Particionar “Aparência=chuva”



Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₄	chuva	70	96	falso	sim
E ₅	chuva	68	80	falso	sim
E ₁₀	chuva	75	80	falso	sim

Exemplo	Aparência	Temperatura	Umidade	Ventando	Jogar
E ₆	chuva	65	70	verdadeiro	não
E ₁₄	chuva	71	91	verdadeiro	não

Árvore de Decisão Induzida



Poda

- ❑ Há duas formas de produzir árvores mais simples
 - **pré-poda**: decide-se não mais particionar o conjunto de treinamento, utilizando algum critério
 - **pós-poda**: induz-se a árvore completa e então remove-se alguns dos ramos
- ❑ A poda invariavelmente causará a classificação incorreta de exemplos de treinamento
- ❑ Conseqüentemente, as folhas não necessariamente conterão exemplos de uma única classe

Pré-Poda

- ❑ Evita gastar tempo construindo estruturas (sub-árvores) que não serão usadas na árvore final simplificada
- ❑ O método usual consiste em analisar a melhor forma de particionar um subconjunto, mensurando-a sob o ponto de vista de significância estatística, ganho de informação, redução de erro ou outra métrica qualquer
- ❑ Se a medida encontrada encontrar-se abaixo de um valor limite (*threshold*) o particionamento é interrompido e a árvore para aquele subconjunto é apenas a folha mais apropriada
- ❑ Entretanto, a definição do valor limite não é simples de ser definido
 - Um valor muito grande pode terminar o particionamento antes que os benefícios de divisões subsequentes tornem-se evidentes
 - Um valor muito pequeno resulta em pouca simplificação

Pós-Poda

- ❑ O processo de indução (*dividir-e-conquistar*) da árvore continua de forma livre e então a árvore super-ajustada (*overfitted tree*) produzida é então podada
- ❑ O custo computacional adicional investido na construção de partes da árvore que serão posteriormente descartadas pode ser substancial
- ❑ Entretanto, esse custo é compensador devido a uma maior exploração das possíveis partições
- ❑ Crescer e podar árvores é mais lento, mas mais confiável

Pós-Poda

- ❑ Existem várias forma de avaliar a taxa de erro de árvores podadas, dentre elas
 - avaliar o desempenho em um subconjunto separado do conjunto de treinamento (o que implica que uma parte dos exemplos devem ser reservada para a poda e, portanto, a árvore tem que ser construída a partir de um conjunto de exemplos menor)
 - avaliar o desempenho no conjunto de treinamento, mas ajustando o valor estimado do erro, já que ele tem a tendência de ser menor no conjunto de treinamento

Interpretação Geométrica

- ❑ Consideramos exemplos como um vetor de m atributos
- ❑ Cada vetor corresponde a um ponto em um espaço m -dimensional
- ❑ A AD corresponde a uma divisão do espaço em regiões, cada região rotulada como uma classe

Interpretação Geométrica: Atributo-Valor



- Um teste para um atributo é da forma

$$X_i \text{ op Valor}$$



onde X_i é um atributo, $op \in \{=, \neq, <, \leq, >, \geq\}$ e valor é uma constante válida para o atributo

- O espaço de descrição é particionado em regiões retangulares, nomeadas hiperplanos, que são ortogonais aos eixos
- As regiões produzidas por uma AD são todas hiperplanos
- Enquanto a árvore está sendo formada, mais regiões são adicionadas ao espaço



Interpretação Geométrica p/ DT



Interpretação Geométrica p/ DT



Interpretação Geométrica p/ DT



Combinação Linear de Atributos



- ❑ Produzem árvores de decisão oblíquas
- ❑ A representação para os testes são da forma

$$a_1 \times X_1 + a_2 \times X_2 + \cdots + a_m \times X_m \text{ op } Valor$$

onde a_i é uma constante, X_i é um atributo real, $op \in \{<, \leq, >, \geq\}$ e $Valor$ uma constante

- ❑ O espaço de descrição é particionado hiperplanos que não são necessariamente ortogonais ao eixos

Árvore de Decisão Oblíqua



Resumo

- ❑ Árvores de decisão, em geral, possuem um tempo de aprendizado relativamente rápido
- ❑ Árvores de decisão permitem a classificação de conjuntos com milhões de exemplos e centenas de atributos a uma velocidade razoável
- ❑ É possível converter para regras de classificação, podendo ser interpretadas por seres humanos
- ❑ Precisão comparável a outros métodos