



Retrieval-Augmented Generation: um spoiler no DeepSeek

Retrieval-Augmented Generation: a DeepSeek spoiler

Patrícia Nascimento Silva

Universidade Federal de Minas Gerais, Belo Horizonte, Minas Gerais, Brasil, e-mail: patricians@ufmg.br

ORCID: 0000-0002-2405-8536

DOI: 10.22477/ISKO25.32

Resumo

Soluções baseadas na geração aumentada de recuperação, ou Retrieval-Augmented Generation (RAG), que permitem a recuperação combinada em bancos de dados e outras fontes confiáveis para potencializar a recuperação em LLMs, são fundamentais para garantir a credibilidade das informações recuperadas nesses ambientes, que enfrentam problemas associados à falta de contexto e a dados incorretos. Com o lançamento dos primeiros *chatbots* da chinesa DeepSeek, com código aberto, modelos simplificados e executáveis localmente que possuem um desempenho similar ou melhor que grandes modelos do mercado, questiona-se se o modelo DeepSeek R1 suporta soluções RAG simplificadas. Assim, este estudo tem como objetivo realizar uma breve análise da recuperação de informação na ferramenta DeepSeek, apoiada em fontes de dados externas, bem como avaliar a pertinência dos resultados sob a dimensão aplicada da organização do conhecimento. Para tanto, foram selecionados documentos do domínio acadêmico, criados *prompts* relacionados ao conteúdo específico e realizada uma análise na ferramenta *web* em fevereiro de 2025. Os resultados apontaram que todas as 10 perguntas realizadas foram recuperadas de forma correta, com destaque para elementos essenciais envolvendo contextos e interpretações da linguagem natural. Além disso, a ferramenta conseguiu recuperar e associar conceitos em documentos pdf, como imagem, de forma satisfatória. Conclui-se que o DeepSeek apresentou bom desempenho e possui funcionalidades que permitem implementar técnicas de RAG para a recuperação de informação em acesso gratuito.

Palavras-chave: Recuperação de informação. Inteligência artificial. Retrieval-augmented generation. LLM. DeepSeek.

Abstract


Solutions based on Retrieval-Augmented Generation (RAG), which allow combined retrieval in databases and other reliable sources to boost retrieval in LLMs, are fundamental to guaranteeing the reliability of the information retrieved in these environments, which face problems associated with lack of context and incorrect data. With the launch of DeepSeek's first chatbots, with open source code, simplified and locally executable models with similar or better performance than large models on the market, it is questionable whether the DeepSeek R1 model supports simplified RAG solutions. The aim of this study is, therefore, to carry out a brief analysis of information retrieval in the DeepSeek tool, based on external data sources, and to assess the relevance of the results. To this end, documents from the academic domain were selected, prompts related to specific content were created and an analysis was carried out on the web tool in February 2025. The results showed that all 10 questions were retrieved correctly, highlighting essential elements involving contexts and natural language interpretations. In addition, the tool was able to retrieve information from pdf documents as images satisfactorily. We conclude that DeepSeek performed well and has functionalities that allow it to implement RAG techniques for information retrieval free of charge.

Keywords: Information retrieval. Artificial intelligence. Retrieval-augmented generation. LLM. DeepSeek.

Resumen

Las soluciones basadas en Retrieval-Augmented Generation (RAG), que permiten combinar la recuperación en bases de datos y otras fuentes fiables para potenciar la recuperación en LLM, son fundamentales para garantizar la fiabilidad de la información recuperada en estos entornos, que se enfrentan a problemas asociados a la falta de contexto y a datos incorrectos. Con el lanzamiento de los primeros chatbots DeepSeek, con código fuente abierto, modelos simplificados y ejecutables localmente y con un rendimiento similar o superior a los grandes modelos del mercado, cabe preguntarse si el modelo DeepSeek R1 admite soluciones simplificadas de GAR. El objetivo de este estudio es, por tanto, analizar brevemente la recuperación de información en la herramienta DeepSeek, basándose en fuentes de datos externas, y evaluar la relevancia de los resultados. Para ello, se seleccionaron documentos del ámbito académico, se crearon preguntas relacionadas con contenidos específicos y se realizó un análisis en la herramienta web en febrero de 2025. Los resultados mostraron que las 10 preguntas se recuperaron correctamente, haciendo hincapié en los elementos esenciales relacionados con los contextos y las interpretaciones del lenguaje natural. Además, la herramienta fue capaz de recuperar satisfactoriamente información de documentos pdf como imágenes. La conclusión es que DeepSeek obtuvo buenos resultados y dispone de funcionalidades que permiten implementar técnicas RAG libres para la recuperación de información.

Palabras clave: Recuperación de la información. Inteligencia artificial. Recuperación-generación aumentada. LLM. DeepSeek.





1 Introdução

Com o surgimento dos primeiros modelos de inteligência artificial (IA) generativa, os Large Language Models (LLMs) se popularizaram como ferramentas para apoiar diversas atividades, marcando uma mudança fundamental nas interações dos usuários com as informações e o conhecimento. No contexto da recuperação de informação, os LLMs melhoraram a precisão ao permitirem uma correspondência mais sutil entre consultas e documentos, considerando, também, o contexto. No âmbito da reordenação, os modelos aprimorados por LLMs consideram nuances linguísticas mais refinadas ao reordenarem os resultados. A incorporação de módulos de leitura em sistemas de recuperação representa um passo significativo para a geração de respostas abrangentes, em vez de meras listas de documentos (Zhu *et al.*, 2023).

No entanto, apesar dos avanços, grande parte dos problemas de recuperação de informação em LLMs advém da falta de contexto e das alucinações provocadas por dados incorretos. Para solucionar parte desses problemas, surgiram soluções baseadas em geração aumentada de recuperação, ou Retrieval-Augmented Generation (RAG). Soluções baseadas em RAG permitem a recuperação combinada em bancos de dados (privados ou públicos) e outras fontes confiáveis para potencializar a recuperação em LLMs e são fundamentais para a confiabilidade das respostas (AWS, 2025).

Implementar soluções RAG demanda dados estruturados, tratados, organizados, padronizados e contextualizados, além de uma infraestrutura robusta de alta performance com grande desempenho computacional. Contudo, esse cenário passa por mudanças e já há modelos que permitem integrar esse tipo de solução de forma simplificada pelos usuários, em ambiente *web* ou em uma versão local, como é o caso da ferramenta DeepSeek. O DeepSeek lançou seu aplicativo de *chatbot* em janeiro de 2025 e veio quebrar paradigmas ao disponibilizar uma IA de código livre e permitir que o modelo seja executado em máquinas comuns, sem grande poder computacional, concorrendo diretamente com modelos de IA prestigiados no mercado.

Considerando as mudanças recentes e os avanços da área, a questão que orienta esta pesquisa é a seguinte: como o modelo DeepSeek R1 suporta soluções RAG simplificadas? O objetivo do trabalho é realizar uma breve análise da recuperação de informação na ferramenta DeepSeek, apoiada em fontes de dados externas, bem como avaliar a pertinência dos resultados sob a dimensão aplicada da organização do conhecimento. Para tanto, foram selecionados documentos do domínio acadêmico, especificamente as normas acadêmicas da graduação e pós-graduação da Universidade Federal de Minas Gerais, documentos em formatos distintos e com diferentes termos e conceitos particulares desse domínio, mas de conhecimento da autora, para serem inseridos e analisados na ferramenta DeepSeek, por meio de buscas no modelo, de forma exploratória.

O estudo justifica-se para apoiar as atividades de recuperação em bases de conhecimento e outras fontes, privadas ou públicas, especialmente as orientadas a documentos, utilizando os recursos de modelos generativos de IA e destacando a importância da Ciência da Informação em novas soluções envolvendo a recuperação de informação e a dimensão aplicada da organização do conhecimento. Destaca-se que este estudo integra um projeto maior, que investiga dados abertos e fontes abertas para a difusão do conhecimento e seu impacto para a inovação e a transformação social.


2 Organização e recuperação da informação

Conforme Mooers (1951), a recuperação de informação (RI) emergiu como um campo do conhecimento científico visando solucionar três desafios decorrentes da explosão de informações: a representação da informação, a especificação de como realizar a busca da informação e a criação de mecanismos eficazes para a recuperação dos dados. Assim, a recuperação de informação trata da:

[...] representação, armazenamento, organização e acesso a itens de informação, como documentos, páginas Web, catálogos online, registros estruturados e semiestruturados, objetos multimídias, etc. A representação e a organização dos itens de informação devem fornecer aos usuários facilidade de acesso às informações de seu interesse (Baeza-Yates; Ribeiro-Neto, 2013, p.1).

Com o passar dos anos e as significativas evoluções das tecnologias e dos suportes de informação, as primeiras aplicações da inteligência artificial na recuperação de informação oportunizaram a evolução nos sistemas e a adaptação da informação de acordo com os interesses de busca do usuário, seja por meio de assistentes virtuais, de *chatbots* e, mais recentemente, dos modelos generativos, com LLMs e soluções RAG, para a inclusão de um *corpus* que permita a expansão da consulta (Alaofi *et al.*, 2024).

Seguindo os princípios da RI, em que a recuperação de dados em um Sistema de Recuperação de Informação (SRI) consiste em identificar, dentro de uma coleção, os documentos que contêm a palavra-chave inserida na consulta do usuário (Baeza-Yates; Ribeiro-Neto, 2013), o RAG implementa a recuperação em sistemas ao utilizar bases de





conhecimento confiáveis para estender os recursos dos LLMs em domínios específicos, sem a necessidade de um novo treinamento do modelo (AWS, 2025).

Com isso, apoiado na definição de Lancaster (1979), que caracteriza a RI como um processo para localizar documentos em uma coleção específica, o RAG potencializa a recuperação em LLMs, e a perspectiva da organização da informação (OI) e do conhecimento (OC) deve ser considerada. Essas abordagens se complementam, pois:

“[...] enquanto na área de OC organiza-se o conhecimento a partir da modelagem de domínios, representando sua estrutura com base na descrição de conceitos e dos relacionamentos semânticos entre eles, na área de OI ocorre o processo de representação do conteúdo de um documento específico, o qual tem o conhecimento registrado, para que ele seja posteriormente recuperado pelo usuário em um Sistema de Recuperação da Informação (SRI)” (Lima, 2016, p. 71).

Com isso, destaca-se a importância da organização para a recuperação de informação e sua relação direta com a Ciência da Informação (CI).

A CI, por meio dos processos de representação, organização e recuperação da informação, fornece subsídios teóricos para compreender como os sistemas organizam e utilizam o conhecimento para aprimorar sua capacidade de tomada de decisão (Capurro; Hjørland, 2003). A recuperação de informação em modelos generativos e LLMs é mais uma faceta a ser explorada na atualidade sob a perspectiva da CI.

3 Metodologia


Este *short paper* é um relato de experiência de uma pesquisa de natureza aplicada, com objetivo exploratório, realizada na ferramenta Deepseek R1, em fevereiro de 2025. A pesquisa exploratória busca imprimir maior familiaridade com o problema, visando torná-lo mais claro ou formular hipóteses (Gil, 2022). Neste estudo, foi explorada a utilização de um RAG, simplificado, no modelo DeepSeek R1.

O DeepSeek foi lançado em 2025, com desempenho pareado ao OpenAI-o1, modelo e relatório técnico totalmente de código aberto, sob a licença Massachusetts Institute of Technology (MIT), com livre distribuição e comercialização (Deepseek, 2025). A ferramenta suporta o idioma português e as respostas são coesas nesse idioma.

O estudo foi dividido em duas etapas. A primeira etapa envolveu a seleção de documentos com elementos de um domínio específico para a implementação do RAG. O domínio selecionado foi o acadêmico, por ser de grande conhecimento da autora e por possuir documentos de acesso público, sem nenhum tipo de restrição. A partir dessa definição, foram buscados documentos sobre a norma acadêmica da graduação e da pós-graduação da Universidade Federal de Minas Gerais. Foram selecionados dois arquivos distintos e específicos, um detalhando as normas gerais da graduação e outro com as normas gerais da pós-graduação. Estes dois documentos estão no mesmo formato (pdf), mas possuem diferenças significativas para recuperação de texto, uma vez que um documento permite copiar o texto e o outro está em formato de imagem, necessitando de conversões.

Para a implementação do RAG, foi realizado um teste local com o modelo R1:7B (7 bilhões de parâmetros), mas, devido à necessidade de utilização de várias bibliotecas externas para a extração e criação de índices nos arquivos, optou-se por realizar o teste diretamente na ferramenta *web*, visto que o estudo é simplificado e pretende explorar o modelo do DeepSeek de forma direta. Porém, destaca-se que a solução local é viável e deve ser considerada para soluções que envolvam dados privados e sigilosos.

Ao entrar no site <https://www.deepseek.com/>, o usuário deve selecionar o tipo de acesso, *web* ou aplicativo, e realizar o *login*. O cadastro é obrigatório para utilizar a ferramenta. Para utilizar o *chat* deve-se acessar o endereço <https://chat.deepseek.com/>. Na opção “new chat”, a ferramenta permite selecionar “Deep Think (R1)” e “Search”. A primeira opção considera somente o modelo, e a segunda inclui a busca na *web*, ambas podem ser utilizadas de forma isolada ou combinada. Para este estudo, foi selecionada somente a primeira opção, conforme apresentado na Figura 1.






Figura 1 – Interface inicial (home) DeepSeek

Na tela inicial, há uma funcionalidade para anexar documentos (ícone de anexo) que permite fazer o *upload* de vários documentos e imagens de uma única vez. Assim, os dois documentos selecionados foram enviados e carregados na ferramenta. Em seguida, foram criados três *prompts*, com blocos de perguntas, totalizando 10 perguntas.

No *Prompt 1* (Quadro 1), foram criadas perguntas específicas sobre o tempo de integralização na graduação e na pós-graduação. Essas informações estão no conteúdo dos documentos, porém de forma dispersa. No *Prompt 2* (Quadro 2), foram realizadas perguntas específicas, que não são encontradas diretamente no texto, demandando uma contextualização do modelo.

Prompt 1:

Considerando os arquivos enviados como RAG, responda às perguntas a seguir:

- 1) Um aluno de graduação possui quanto tempo para integralizar?
- 2) Um aluno de pós-graduação (mestrado) possui quanto tempo para integralizar?
- 3) Um aluno de pós-graduação (doutorado) possui quanto tempo para integralizar?
- 4) Um aluno de mestrado deve cumprir quais requisitos para obter o título de mestre?

Quadro 1 - Perguntas do Prompt 1


Prompt 2:

Considerando os arquivos enviados como RAG, responda às perguntas a seguir:

- 1) Um aluno de graduação ou pós-graduação pode interromper seu curso? Como proceder?
- 2) Um discente com o conceito B obteve qual pontuação?
- 3) Um professor colaborador pode orientar quantos alunos?
- 4) Quais são os percursos curriculares possíveis para um curso de graduação?

Quadro 2 - Perguntas do Prompt 2

O *Prompt 3* (Quadro 3) incluiu duas perguntas amplas, predominantemente em linguagem natural, simulando uma conversa com a ferramenta:





Prompt 3:

Considerando os arquivos enviados como RAG, responda às perguntas a seguir:

- 1) Sou aluno de graduação. Quais elementos são fundamentais para ter um bom desempenho acadêmico?
- 2) Sou aluno de pós-graduação. Quais elementos são fundamentais para ter um bom desempenho acadêmico?

Quadro 3 - Perguntas do Prompt 3

Na segunda etapa, foram analisadas as respostas obtidas pela ferramenta. Foi considerada a pertinência das respostas em relação aos conteúdos dos documentos e foram observadas as funcionalidades relacionadas aos resultados apresentados, bem como o desempenho da ferramenta de forma geral.


É importante destacar que o modelo R1:7B, disponibilizado de forma aberta, pode ser executado em outras plataformas, como o Ollama, para a execução do modelo R1 localmente. Contudo, para este estudo, que considerou um volume pequeno de dados e trata-se de um breve experimento, optou-se por utilizar a versão *web*. O título deste *short paper* foi criado de forma sugestiva e intencional, utilizando a palavra *spoiler*, que popularmente significa antecipar detalhes importantes para usuários que ainda não conhecem a ferramenta, a fim de trazer a pesquisa para o contexto da sociedade, fomentando o debate.

3 Resultados

Nesta seção, serão apresentados os resultados obtidos na ferramenta DeepSeek R1, em seu ambiente *web*. O primeiro destaque, até o presente momento (fevereiro de 2025), é o acesso gratuito à ferramenta, que possui poucas limitações. Quando comparado a outras ferramentas / modelos generativos do mercado, observou-se que o DeepSeek permite um número muito maior de envio de perguntas sequenciais em acesso gratuito (mais de 20, em um teste realizado) e o envio de vários arquivos em um único *prompt*. Essa última funcionalidade existe em outros modelos, mas somente nas versões pagas. A indisponibilidade do servidor, que exibe a mensagem: “*The server is busy. Please try again later*”, foi observada em algumas tentativas, de forma intermitente, mas, após alguns minutos, foi possível retomar as consultas.

O envio de vários arquivos (texto e imagens) é limitado a 50 documentos, com o tamanho de até 100 MB cada. Essa quantidade permite que o modelo suporte técnicas de RAG de forma simplificada. O RAG mescla as capacidades generativas de LLMs com informações externas específicas de domínio, melhorando tanto a confiabilidade quanto a clareza das respostas produzidas (Lecu; Groza; Hawizy, 2025). Para o estudo, foram utilizados somente dois arquivos, porém com um conteúdo muito específico, o que permitiu avaliar a pertinência das respostas da ferramenta no domínio acadêmico.

Com relação às funcionalidades, observou-se que é permitido editar o *prompt* enviado, ajustando a mensagem sem criar uma nova conversa. Há, também, uma visualização dos arquivos carregados, que pode ser acessada ao clicar no nome do arquivo, em uma janela aberta no lado direito da tela (Figura 2). Essa visualização permite ao usuário realizar alguma conferência, sendo um recurso interessante para promover algum tipo de comparação.






Figura 2 - Interface DeepSeek com arquivos carregados


Em relação às respostas obtidas na ferramenta para o *Prompt 1*, que possui um bloco de quatro perguntas simples, que podem ser localizadas de forma direta nos documentos, foi observado que a ferramenta recuperou todas as informações com precisão, fornecendo informações relevantes para a pergunta do usuário, realizada em linguagem natural. Isso indica que o DeepSeek segue a evolução dos modelos dinâmicos de recuperação de informação, utilizando técnicas de IA para permitir a interação do usuário, interferindo no processo de recuperação de informação de acordo com os interesses de busca do usuário e as interações com o sistema (Baeza-Yates; Ribeiro-Neto, 2013; Fernald, 2003).

O mesmo *prompt* foi executado mais de uma vez e foi possível observar que a ferramenta gera respostas similares, mas não iguais. A resposta é apresentada em três partes: inicialmente, é apresentado o trecho do documento no qual o assunto foi localizado. Na segunda parte, as respostas são destacadas em negrito no texto e apresentadas de forma objetiva. Na terceira parte, às vezes, é apresentado um resumo, com a resposta direta, ou as referências utilizadas, citando, em detalhes, o artigo ou a seção do documento para fundamentar cada resposta (APÊNDICE - Figura 1).

Em algumas execuções, foi observado que a ferramenta gerou somente duas partes, mas fez a indicação do artigo e da seção como uma referência: “Em graduação e pós-graduação, o conceito B corresponde à pontuação entre 80 e 89 (Art. 12, §3º das Normas de Graduação; Art. 70 das Normas de Pós-Graduação)”. Em um RI, a relevância dos resultados envolve questões humanas e técnicas (Monteiro *et al.*, 2017) ao considerar a similaridade entre a representação da expressão de busca e a representação dos documentos do *corpus* pesquisado, em conjunto com a genuinidade do documento recuperado. Este último item fica claro quando a ferramenta indica o artigo ou a seção do documento. Indicar o número da página ou o parágrafo também seria um recurso interessante para a localização da informação dentro do documento, mas esse tipo de marcação não foi realizada no DeepSeek para o *prompt* utilizado.

Para Dahlberg (1993), a organização do conhecimento é definida como uma ciência que estrutura e organiza sistematicamente unidades do conhecimento (conceitos) segundo seus elementos de conhecimento (características) inerentes e a aplicação desses conceitos e classes de conceitos, ordenados a objetos ou assuntos. Quando o DeepSeek indica o artigo ou a seção das Normas, essa estrutura de organização precisa ser criada pela ferramenta. Conforme Bräsher e Carlan (2010), a qualidade alcançada na recuperação da informação depende substancialmente dos instrumentos utilizados. Assim, os padrões de organização devem ser definidos desde a concepção do sistema para permitir que a informação seja encontrada posteriormente.

Em relação às respostas obtidas na ferramenta para o *Prompt 2* (APÊNDICE - Figura 2), que inclui quatro perguntas específicas e com contexto, a ferramenta também obteve um ótimo desempenho, apresentando todas as respostas corretas. Nesse *prompt*, foi avaliado se a ferramenta conseguiria fazer a associação da expressão “interrupção do curso” em linguagem natural, com um termo específico do contexto acadêmico: “trancamento”. Destaca-se que a palavra interrupção não existe em nenhum dos documentos selecionados.





O resultado foi positivo, pois a ferramenta fez a associação correta e apresentou os tipos de trancamento. Essa associação pode ser apoiada na teoria do conceito, especificamente no triângulo conceitual de Dahlberg (1978). Nele, o referente é a situação a ser nomeada (quando o aluno precisa interromper seu curso), as características correspondem aos enunciados verdadeiros, ou seja, às propriedades atribuídas, explicitando o processo de predicação apontado, e a forma verbal em que um termo será utilizado para sintetizar e representar o referente a partir de um consenso definido, tendo em vista os propósitos da comunicação e configurando o processo de denotação, no documento analisado definido como trancamento.

A ferramenta também consegue fazer a associação para tipos e faixa de valores, indicando a quantidade de orientandos para docentes colaboradores e as notas para um conceito. Os percursos curriculares também foram indicados corretamente, apesar de essa informação não ser disposta de forma completa em um único trecho do documento, uma vez que há vários detalhamentos para os percursos.

Para Dahlberg (2006), há duas aplicações para a organização do conhecimento: (a) construção de sistemas conceituais; e (b) a correlação ou o mapeamento de unidades desse sistema conceitual com objetos da realidade. Considerando a primeira aplicação sugerida, os sistemas de organização do Conhecimento (SOC) são tipos de sistemas conceituais ou tipos de representações do conhecimento, ambos frutos do processo de organização do conhecimento. Nesse sentido, os SOCs são aplicados para mapear objetos informacionais, isto é, para representar os assuntos dos documentos num sistema de informação. Essa definição indica os SOCs como uma aplicação exequível no contexto dos LLMs

Em relação às respostas obtidas na ferramenta para o *Prompt 3* (APÊNDICE - Figura 3), os resultados indicaram elementos pertinentes tanto para a graduação quanto para a pós-graduação, como: assiduidade, notas e conceitos (mínimo 60 pontos), participação em atividades diversas, integralização de créditos, gestão do tempo (respeitar o tempo máximo de integralização), aproveitamento de estudos, planejamento curricular, interdisciplinaridade e internacionalização, e finaliza com a seguinte observação: “Em ambos os casos, a organização pessoal, o diálogo com orientadores/colegiados e o cumprimento de prazos são essenciais para evitar penalidades acadêmicas”. A síntese realizada priorizou elementos que são essenciais para manter o aluno matriculado e para obter o título almejado.

Para os três *prompts*, a ferramenta indicou, nas respostas, que utilizou os documentos fornecidos para gerar a resposta, demonstrando ter considerado as fontes externas, ou seja, técnicas de RAG, para recuperação de informação. Um ponto positivo da ferramenta foi que, para o documento em pdf com imagens, o texto foi recuperado sem intercorrências, indicando que alguma transformação, de OCR para texto, por exemplo, foi executada internamente pelo modelo.

Em linhas gerais, a ferramenta DeepSeek demonstrou bom desempenho em sua primeira versão (R1). Ao realizarem testes em outros modelos generativos do mercado, como ChatGPT e Bard, Nascimento Silva (2023) e Nascimento Silva (2024) apontaram a ausência de itens essenciais que foram identificados no DeepSeek, como a indicação da fonte das informações, a completude e a veracidade das respostas.


Apesar de não ter sido utilizado o modelo R1:7B, disponibilizado de forma aberta, soluções de RAG envolvendo o DeepSeek e outras plataformas, como o Ollama, para a execução modelo R1 localmente, têm utilizado técnicas de *chunks*, que são as combinações ou os grupos de palavras, e a criação de vetores e índices com bibliotecas Python. Muitas são as possibilidades e integrações existentes e, para compreender melhor as soluções e os algoritmos utilizados, é essencial que a organização da informação seja investigada, sendo o profissional da informação um ator importante para contribuir com a evolução da área.

Apesar das limitações deste estudo, que foi realizado em pequena escala e sem uma análise aprofundada, é importante destacar que o DeepSeek, em sua versão inicial (R1), supera as expectativas e promete fazer uma revolução no mercado dos modelos de IA generativa.

4 Conclusão

Este *short paper* objetivou realizar uma breve análise da recuperação de informação na ferramenta DeepSeek, apoiada em fontes de dados externas, bem como avaliar a pertinência dos resultados sob a dimensão aplicada da organização do conhecimento. Para tanto, foram selecionados documentos específicos sobre norma acadêmica da Universidade Federal de Minas Gerais para graduação e pós-graduação.

A partir da análise realizada, foi possível observar que as informações foram recuperadas de forma pertinente nos documentos, indicando que uma solução simplificada para RAG é viável na ferramenta, em acesso gratuito. Mesmo para perguntas mais específicas e com contexto, a ferramenta apresentou bom desempenho, fazendo associações corretas em todas as 10 perguntas realizadas.





Funcionalidades de visualização complementam as respostas para o usuário, que pode acessar o documento para realizar conferências. A apresentação das respostas em partes e com destaques também é outro ponto positivo da ferramenta, que sintetiza muito bem o conteúdo, sendo direta e objetiva em alguns pontos, atendendo tanto usuários que precisam de um maior detalhamento quanto usuários que precisam de uma resposta rápida e direta.


Conclui-se que a ferramenta implementa técnicas de RAG em sua versão mais simples e *web*, permitindo a identificação e associação de conceitos em uma dimensão aplicada da organização do conhecimento. Como trabalhos futuros, é importante investigar o desempenho da ferramenta para grandes volumes de dados, integrado com metadados, grafos de conhecimento, ontologias e outros instrumentos da CI para organização da informação e do conhecimento.

Agradecimento

À Fundação de Amparo à Pesquisa do Estado de Minas Gerais (FAPEMIG) APQ-01609-24.

Referências

- ALAOFI, M. *et al.* Generative information retrieval evaluation. In: **Information Access in the Era of Generative AI**. Cham: Springer Nature Switzerland, 2024. p. 135-159.
- AWS. **O que é RAG (Retrieval-Augmented Generation)?** 2025. Disponível em: <https://aws.amazon.com/what-is/retrieval-augmented-generation/>. Acesso em: 19 nov. 2024.
- BAEZA-YATES, R.; RIBEIRO-NETO, B. **Recuperação de Informação: Conceitos e tecnologia das máquinas de busca**. 2. ed. Porto Alegre: Bookman, 2013.
- BRÄSCHER, M.; CARLAN, E. Sistemas de organização do conhecimento: Antigas e novas linguagens. In: Jaime Robredo; Marisa Bräscher (Orgs.). **Passeios no Bosque da Informação: Estudos sobre Representação e Organização da Informação e do Conhecimento – EROIC**. Brasília DF: IBICT, 2010, 335 p. Capítulo 8, p. 147-176. Edição eletrônica. Disponível em: <http://www.ibict.br/publicacoes/eroic.pdf>. Acesso em: 28 abril 2025.
- CAPURRO, R.; HJØRLAND, B. The Concept of Information. **Annual Review of Information Science and Technology**, v. 37, n. 1, p. 343-411, 2003.
- DAHLBERG, I. A Referent-oriented, Analytical Concept Theory of Interconcept. **International Classification**, v. 5, p. 122-151, 1978.
- DAHLBERG, I. **Knowledge organization: its scope and possibilities**. Knowledge Organization, 20(4), 211-222, 1993.
- DAHLBERG, I. **Knowledge organization: a new science?** Knowledge Organization, v. 33, n. 4, p. 11-19, 2006.
- DEEPSEEK. **DeepSeek-R1 Release**. Disponível em: <https://api-docs.deepseek.com/news/news250120>. Acesso em: 19 fev. 2025.
- FERNEDA, E. **Introdução aos Modelos Computacionais de Recuperação de Informação**. Rio de Janeiro: Editora Ciência Moderna Ltda. 2012.
- GIL, A. C. **Como elaborar projetos de pesquisa**. 7. ed. São Paulo: Atlas, 2022.
- HJØRLAND, B. **What is knowledge organization (KO)?** Knowl. Org., Germany, v. 35, n. 2, p. 86- 111, jul. 2008. Disponível em: DOI:10.5771/0943-7444-2008-2-3- 86. Acesso em: 15 fev. 2025.
- LANCASTER, F. W. **Information retrieval systems**. 2. ed. New York: Wiley, 1979. Disponível em: <https://catalogue.nla.gov.au/catalog/2521689>. Acesso em: 10 fev. 2025.
- LECU, A.; GROZA, A.; HAWIZY, L. Knowledge Graph-Driven Retrieval-Augmented Generation: Integrating Deepseek-R1 with Weaviate for Advanced Chatbot Applications. **arXiv preprint arXiv:2502.11108**, 2025.
- LIMA, G. Â. de. Da organização do conhecimento à recuperação da informação: teorias e técnicas. In: **SEMINÁRIO DO GRUPO DE PESQUISA MHTX**, 2., 2016, Belo Horizonte. Anais [...] Belo Horizonte: Universidade Federal de Minas Gerais, 2016. p. 67–80. Disponível em: <https://repositorio.ufmg.br/bitstream/1843/41403/2/Da%20organiza%C3%A7%C3%A3o%20do%20conhecimento%20>





[%C3%A0%20recupera%C3%A7%C3%A3o%20da%20informa%C3%A7%C3%A3o_teorias%20e%20t%C3%A9cnicas.pdf](#). Acesso em: 29 abr. 2025.


MONTEIRO, D. *et al.* Sistemas de recuperação da informação e o conceito de relevância nos mecanismos de busca: semântica e significação. **Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação**, Florianópolis, v. 22, n. 50, p. 161–175, Informação & Sociedade, João Pessoa, v.33, 2023. 2017. DOI: 10.5007/1518-2924.2017v22n50p161. Disponível em: <https://periodicos.ufsc.br/index.php/eb/article/view/1518-2924.2017v22n50p161>. Acesso em: 19 fev. 2023

MOOERS, C. N. Zatocoding applied to mechanical Organization of Knowledge. **American Documentation**, v. 2, n. 1, p. 20-32, 1951.

NASCIMENTO SILVA, P. Recuperação de informação na Web: uma experiência com o modelo de linguagem de inteligência artificial ChatGPT. **Informação em Pauta**, Fortaleza, v. 8, p. 1–19, 2023. DOI: 10.36517/2525-3468.ip.v8i0.2023.83566.1-19. Disponível em: <http://www.periodicos.ufc.br/informacaoempauta/article/view/83566>. Acesso em: 19 fev. 2025.

NASCIMENTO SILVA, P. Recuperação de informação na Web com o Bard: uma experiência com a inteligência artificial generativa da Google. **Informação & Sociedade; Sociedade**, João Pessoa, v. 33, 2024. Disponível em: <https://periodicos.ufpb.br/index.php/ies/article/view/67458>. Acesso em: 19 fev. 2025.

ZHU, Y. *et al.* Large language models for information retrieval: A survey. **arXiv preprint arXiv:2308.07107**, 2023. Disponível em: <https://doi.org/10.48550/arXiv.2308.07107>. Acesso em: 19 fev. 2025.





APÊNDICE

Vou analisar os documentos fornecidos para responder às perguntas sobre os prazos de integralização e requisitos para obtenção de títulos na Universidade XXXX.

Primeiro, para a graduação: no arquivo "NGG graduação.pdf", no Art. 49, § 1º, menciona que o tempo máximo de integralização do percurso curricular é calculado dividindo o tempo padrão por 3/5 e arredondando para o número inteiro superior. Por exemplo, se o tempo padrão for 4 anos (8 períodos), o máximo seria $(8 / (3/5)) =$ aproximadamente 13,33, arredondando para 14 períodos. Mas preciso verificar se há uma referência direta ao tempo padrão.

No mesmo documento, Art. 87, inciso III, fala sobre o desligamento caso ultrapasse o tempo máximo de integralização atribuído. O Art. 85 explica que o tempo máximo é definido no Art. 49. Portanto, o tempo máximo depende do curso, mas o padrão parece ser calculado com base na fórmula mencionada.

Para a pós-graduação (mestrado e doutorado), no arquivo "NGG pós-graduação.pdf", Art. 82 (mestrado) e Art. 83 (doutorado) estabelecem prazos mínimos e máximos. O mestrado tem prazo mínimo de 12 meses e máximo definido no regulamento do curso. O doutorado tem mínimo de 24 meses e máximo no regulamento. Além disso, no Art. 84, há possibilidade de alteração desses prazos em casos excepcionais.

Sobre os requisitos para o título de mestre, no Art. 82 do documento de pós-graduação, listam-se os requisitos: completar créditos, aprovação em exame de língua estrangeira, defesa da dissertação, e entrega da versão final.

Assim, as respostas seriam:

1) **Graduação:** Tempo máximo calculado como (tempo padrão / 3/5), arredondado para cima. Por exemplo, se o tempo padrão for 4 anos (8 períodos), máximo ≈ 14 períodos (7 anos). Mas pode variar por curso.

2) Mestrado: Mínimo 12 meses, máximo conforme regulamento do curso.

3) Doutorado: Mínimo 24 meses, máximo conforme regulamento do curso.

4) Requisitos para mestrado: Completar créditos, aprovar exame de língua estrangeira, defender dissertação, entregar versão final.

1. **Tempo para integralização na graduação:**

2. O tempo máximo de integralização é calculado dividindo o tempo padrão do curso por 3/5, arredondando o resultado para o número inteiro superior. Por exemplo, se o curso tem um tempo padrão de 4 anos (8 períodos letivos), o máximo será $\frac{8}{3/5} \approx 13,33$, arredondado

para 14 períodos (7 anos). Esse prazo pode variar conforme o curso, mas segue a fórmula do Art. 49, § 1º das Normas Gerais de Graduação.

3. **Tempo para integralização no mestrado:**

Mínimo de 12 meses e máximo definido no regulamento do curso (Art. 82 das Normas Gerais de Pós-Graduação). Casos excepcionais podem ter prazos ajustados (Art. 84).

4. **Tempo para integralização no doutorado:**

Mínimo de 24 meses e máximo definido no regulamento do curso (Art. 83 das Normas Gerais de Pós-Graduação). Excepcionalmente, o prazo pode ser alterado (Art. 84).

5. **Requisitos para título de mestre:**

- Completar o número mínimo de créditos exigidos;
- Aprovação em exame de língua estrangeira (conforme legislação pertinente);
- Defesa pública de dissertação, demonstrando domínio do tema e metodologia;
- Entrega da versão final da dissertação, incorporando as correções da Comissão Examinadora (Art. 82 das Normas Gerais de Pós-Graduação).

Respostas resumidas:


1. **Graduação:** Tempo máximo = $\frac{\text{Tempo padrão}}{3/5}$, arredondado para cima.


2. **Mestrado:** 12 meses (mínimo) + prazo máximo do regulamento.

3. **Doutorado:** 24 meses (mínimo) + prazo máximo do regulamento.

4. **Requisitos para mestrado:** Créditos, exame de língua, defesa de dissertação e entrega final.

Figura 1 - Resultado do Prompt 1





Ok, vou tentar responder às perguntas baseadas nos documentos fornecidos. Vou começar analisando cada uma das questões passo a passo.

****1) Um aluno de graduação ou pós-graduação pode interromper seu curso? Como proceder?***

Primeiro, vou verificar as seções relacionadas à interrupção de cursos nos documentos de graduação e pós-graduação.

****Para Graduação:***

No documento de graduação (NGG graduação.pdf), há menção sobre "trancamento de matrícula". No Título VI, Capítulo II, Seção V, Art. 95 a 98 discutem o trancamento total e parcial de matrícula. Por exemplo, o Art. 95 permite ao estudante solicitar trancamento total ou parcial. O Art. 96 detalha os prazos e condições para trancamento total, incluindo justificativas. O Art. 97 aborda o trancamento parcial. Além disso, o Art. 87 menciona desligamento por ultrapassar o tempo máximo de integralização.

****Para Pós-Graduação:***

No documento de pós-graduação (NGG pós-graduação.pdf), no Título V, Art. 58 e seguintes falam sobre matrícula e trancamento. Por exemplo, Art. 59 e 60 permitem trancamento parcial ou total, com anuência do orientador no caso de cursos *stricto sensu*.

****Resposta:***

Sim, tanto alunos de graduação quanto de pós-graduação podem interromper seus cursos. Na graduação, o trancamento total ou parcial é permitido mediante solicitação, com regras específicas de prazos e justificativas. Na pós-graduação, o trancamento também é possível, com necessidade de aprovação do orientador ou colegiado, dependendo do tipo de curso (*lato* ou *stricto sensu*).

****2) Um discente com o conceito B obteve qual pontuação?***

Preciso ver a escala de conceitos nos dois documentos.

****Graduação:***

No Título III, Art. 12, §3º, a escala é:

- A: 90-100
- B: 80-89
- C: 70-79
- D: 60-69
- E: 40-59
- F: <40 ou assiduidade insuficiente.

****Pós-Graduação:***

No Título VI, Art. 70:

- A: 90-100
- B: 80-89
- C: 70-79
- D: 60-69
- E: 40-59
- F: 0-39.

****Resposta:***

Um conceito B corresponde a pontuação entre 80 e 89 pontos, tanto na graduação quanto na pós-graduação.

****3) Um professor visitante pode ser colaborador em um programa de pós-graduação?***

No documento de pós-graduação, Título IV, Subtítulo II, Capítulo II, Art. 43 menciona docentes colaboradores e visitantes. §1º indica que docentes visitantes podem ser credenciados desde que tenham título de Doutor e aprovação do colegiado e PRPG.

****Resposta:***

Sim, professores visitantes podem ser credenciados como colaboradores em programas de pós-graduação, desde que atendam aos critérios de titulação e aprovação pelo colegiado do curso e pela PRPG.

****4) Quais são os percursos curriculares possíveis para um curso de graduação?***

No documento de graduação, Título V, Capítulo II, Art. 40 e 41 discutem os percursos curriculares. O Art. 39 define percurso curricular como uma trajetória de formação específica, e o Art. 41 menciona núcleos específico, complementar, geral e avançado. Além disso, o Art. 40 permite flexibilidade na escolha do percurso.

****Resposta:***

Os percursos curriculares na graduação são definidos pela estrutura curricular do curso, que inclui núcleos específicos, complementares, gerais e avançados. Os estudantes podem escolher entre diferentes trajetórias formativas dentro do curso, permitindo integração com outras áreas e até com disciplinas de pós-graduação. Cada percurso pode levar a diferentes habilitações ou diplomas, conforme as escolhas do aluno e as opções oferecidas pelo curso.

Respostas:

1. Interrupção de Curso:

☐ **Graduação:** O aluno pode solicitar trancamento total ou parcial da matrícula. O trancamento total sem justificativa é permitido uma única vez durante o curso, enquanto o trancamento com justificativa requer análise do Colegiado. O tempo máximo de integralização não é estendido em caso de trancamento.

☐ **Pós-Graduação:** É possível trancar a matrícula parcial ou total. Para cursos *stricto sensu* (Mestrado/Doutorado), o trancamento parcial requer anuência do orientador, e o total depende de justificativa aprovada pelo Colegiado. Cursos *lato sensu* (Especialização) permitem trancamento, desde que o aluno conclua dentro do prazo do curso.

Procedimento:

☐ Graduação: Solicitar trancamento via sistema acadêmico, respeitando prazos e regras do calendário escolar.

☐ Pós-Graduação: Encaminhar solicitação formal ao Colegiado do curso, com anuência do orientador (se aplicável).

2. Conceito B:

☐ Corresponde à **pontuação entre 80 e 89 pontos**, tanto na graduação (Art. 12, §3º da NGG Graduação) quanto na pós-graduação (Art. 70 da NGG Pós-Graduação).

3. Professor Visitante como Colaborador:

☐ **Sim**, conforme Art. 43 da NGG Pós-Graduação. Docentes visitantes podem ser credenciados como colaboradores, desde que possuam título de Doutor e tenham aprovação do Colegiado do curso e da Pró-Reitoria de Pós-Graduação (PRPG). Eles podem ministrar disciplinas e orientar até 2 discentes simultaneamente.

4. Percursos Curriculares na Graduação:

☐ São trajetórias formativas flexíveis definidas pela estrutura curricular do curso, que incluem:

Núcleo Específico: Saberes centrais do curso.

Núcleo Complementar: Formação em outra área (via estrutura formativa ou plano individual).

Núcleo Geral: Disciplinas de formação cidadã e crítica.

Núcleo Avançado: Disciplinas de pós-graduação integradas à graduação.

☐ Os percursos podem levar a diferentes habilitações ou diplomas, permitindo ao estudante escolher entre opções como Bacharelado, Licenciatura ou Superior de Tecnologia, conforme Art. 6º e 40 da NGG Graduação.

Referências:

- Graduação: Art. 12, 95-98, 39-41.

- Pós-Graduação: Art. 58-60, 70, 43.






Figura 2 - Resultado do Prompt 2

Ok, vou tentar responder às duas perguntas com base nos documentos fornecidos. Primeiro, para a graduação. Vou precisar olhar o arquivo "NGG graduação.pdf". Lá, no Título III, que trata das Atividades Acadêmicas Curriculares, alguns artigos mencionam a importância da assiduidade (Art. 11), que exige pelo menos 75% de presença. Também, o Art. 12 fala sobre a avaliação do desempenho, com notas de 0 a 100 e conceitos de A a F. Além disso, há menção sobre aproveitamento de estudos e comprovação de conhecimentos. Também tem o Art. 17 sobre o calendário escolar com dois períodos letivos por ano. Acho que elementos como frequência, notas, participação em atividades e cumprimento de créditos são importantes.

Agora, para a pós-graduação, vou ver o "NGG pós-graduação.pdf". No Título VI, sobre o Regime Didático, o Art. 70 estabelece a escala de notas e conceitos. O Art. 71 menciona que alunos com conceito E ou F mais de uma vez são excluídos. Também há exigências para defesa de dissertações e teses, como aprovação em exames de língua estrangeira (Art. 82 e 83), e a necessidade de orientação por um docente credenciado (Art. 46). Além disso, o Art. 64 define os créditos necessários, e o Art. 69 exige exame de qualificação para doutorado. Elementos como orientação adequada, cumprimento de créditos, produção acadêmica e aprovação em exames específicos parecem cruciais.

Preciso verificar se há mais pontos relevantes. Para graduação, talvez a participação em projetos e estágios (Art. 4, tipos de atividades acadêmicas). Para pós, a integração com pesquisa e a apresentação de trabalhos originais (Art. 83). Também, em ambos os casos, a organização do tempo e o cumprimento de prazos máximos para integralização são importantes.

Resposta:

1) Aluno de Graduação: Elementos fundamentais para um bom desempenho acadêmico

- **Assiduidade:** Comparecer a pelo menos **75% das atividades** (Art. 11). Faltas acima disso resultam em reprovação.
- **Notas e Conceitos:** Obter nota mínima de **60 (conceito D)** para aprovação. Notas abaixo de 40 (conceito F) ou duas reprovações com conceito E ou F podem levar à exclusão (Art. 12 e 71 do *NGG graduação.pdf*).
- **Participação em Atividades Diversas:** Engajar-se em projetos, estágios, programas e eventos (Art. 4), que complementam a formação.
- **Integralização de Créditos:** Cumprir a carga horária mínima exigida, respeitando pré-requisitos e correquisitos (Art. 49).
- **Gestão do Tempo:** Respeitar o **tempo máximo de integralização** (calculado com base no tempo padrão do curso) para evitar desligamento (Art. 87).
- **Aproveitamento de Estudos:** Utilizar créditos de mobilidade acadêmica ou comprovação de conhecimentos (Art. 10).
- **Planejamento Curricular:** Seguir os núcleos específico, complementar, geral e avançado, conforme a estrutura do curso (Art. 41-47).

2) Aluno de Pós-Graduação: Elementos fundamentais para um bom desempenho acadêmico

- **Orientação Adequada:** Ter um orientador credenciado e respeitar o limite de orientandos (Art. 46 e 47 do *NGG pós-graduação.pdf*).
 - **Cumprimento de Créditos:** Atender ao número mínimo de créditos exigidos (ex: **360 horas para Especialização**, Art. 81) e aproveitar créditos de disciplinas isoladas (Art. 67).
 - **Produção Acadêmica:** Desenvolver pesquisas originais (para Doutorado) e publicar resultados (Art. 4 e 83).
 - **Exames Específicos:** Aprovação em **exame de língua estrangeira** (para Mestrado/Doutorado) e **exame de qualificação** (obrigatório para Doutorado, Art. 82-83).
 - **Defesa de Trabalho:** Apresentar dissertação, tese ou trabalho final com aprovação unânime da banca (Art. 78).
 - **Frequência e Notas:** Evitar conceitos E ou F em mais de uma disciplina (Art. 71), sob risco de exclusão.
 - **Interdisciplinaridade e Internacionalização:** Participar de atividades que integrem diferentes áreas e promovam intercâmbio (Art. 3º, incisos IV-V).
 - **Prazo Máximo:** Concluir o Mestrado em até **36 meses** e o Doutorado em até **48 meses** (Art. 82-83), com possibilidade de extensão excepcional (Art. 84).
- Observação:** Em ambos os casos, a organização pessoal, o diálogo com orientadores/colegiados e o cumprimento de prazos são essenciais para evitar penalidades acadêmicas.

Figura 3 - Resultado do Prompt 3

